MINISTERUL EDUCAȚIEI

UNIVERSITATEA TEHNICĂ
DIN CLUJ-NAPOCA
FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE

# PREDICȚIA CRIZELOR EPILEPTICE ÎN CADRUL SUBIECȚILOR DIAGNOSTICAȚI

PROIECT DE SEMESTRU

Student: **Victor-Samuel CÎMPEAN**

Disciplina: **Sisteme bazate pe Cunoaștere**

**2026**

Cuprins


**1 INTRODUCERE ... 3**

1.1 CONTEXT GENERAL ... 3
1.2 OBIECTIVE ... 3
1.3 SPECIFICAȚII ... 4
*1.3.1 Funcționalitățile aplicației ... 4*
*1.3.2 Nivele de performanță și fiabilitate ... 5*
*1.3.3 Structuri de date și tehnologii ... 5*
*1.3.4 Reziliența la zgomot și interferențe ... 5*
*1.3.5 Limitări ... 6*

**2 CUNOAȘTEREA ȘI ANALIZA SETULUI DE DATE ... 7**

2.1 STADIUL ACTUAL AL CUNOAȘTERII ... 7
*2.1.1 Abordări pentru Predicția și Detecția Epilepsiei ... 7*
*2.1.2 Tehnici de Procesare Avansată a Semnalului ... 7*
*2.1.3 Paradigme BCI și Control ... 8*
2.1 ANALIZA SETURILOR DE DATE UTILIZATE ... 8
*2.1.1 Introducere ... 8*
*2.1.2 Baza de date CHB-MIT Scalp EEG ... 9*
2.1.2.1 Caracteristici ale subiecților ... 9
2.1.2.2 Detalii tehnice și achiziție ... 11
*2.1.3 Baza de date Siena Scalp EEG ... 11*
2.1.3.1 Profilul clinic al pacienților ... 11
2.1.3.2 Specificații tehnice de înaltă rezoluție ... 11
*2.1.4 Analiza comparativă și preprocesarea pentru unificare ... 11*
2.1.4.1 Standardizarea frecvenței (Downsampling) ... 11
2.1.4.2 Segmentarea și echilibrarea claselor ... 12
*2.1.5 Calitatea datelor și interferențe (zgomot și artefacte) ... 12*

**3 PRE-PROCESAREA SETULUI DE DATE ... 13**

3.1 STANDARDIZAREA FRECVENȚEI DE EȘANTIONARE ... 13
3.2 DESCRIEREA METODELOR DE PRE-PROCESARE APLICATE ... 13
*3.2.1 A. Eliminarea Zgomotului și Filtrarea Spectrală (Step 1) ... 13*
*B. Eliminarea Tendințelor (Detrending) ... 13*
3.3 TRANSFORMATA HILBERT ȘI SEMNALUL ANALITIC ... 14
3.4 SEGMENTAREA ȘI STANDARDIZAREA ... 14
*3.3.1 C. Diferențierea Temporală (Derivata de Ordinul 1) ... 14*
*3.3.2 D. Reducerea Dimensionalității și Referențierea Spațială ... 15*
3.4 SEGMENTAREA DATELOR: (PASUL 4) ... 15
3.5 REZULTATE OBȚINUTE ÎN PRE-PROCESARE ... 15
3.6 INFORMAȚII PENTRU REPRODUCTIBILITATE ... 15

**4 MODELAREA SISTEMULUI ... 16**

4.1 FAZELE FLUXULUI DE DATE ... 16
4.2 INGINERIA TRĂSĂTURILOR (FEATURE ENGINEERING) ... 16
*4.2.1 Line Length (LL) ... 16*
*4.2.2 Energia Focală și Kurtosis ... 16*
*4.2.3 Indicatorul de Focalitate (Inovație Proprie) ... 17*
4.3 TEHNICA DE MODELARE: RANDOM FOREST ... 17
4.4 IMPLEMENTAREA TEHNICĂ ... 17

*4.4.1 Mediul și Bibliotecile Utilizate ... 17*
*4.4.2 Structura Codului ... 17*
4.5 EVALUAREA MODELULUI: METODOLOGIE ȘI EXPERIMENTE ... 17
*4.5.1 Metodologia de evaluare ... 17*
*4.5.2 Experiment 1: Detecția stării preictale ... 18*
*4.5.3 Experiment 2: Testul Negativ (Rezilienta la Zgomot) ... 18*
4.6 CALCULE ȘI PROCEDURI PENTRU REPRODUCERE ... 18
**5 MODELAREA SISTEMULUI ... 18**
5.1 INGINERIA TRĂSĂTURILOR (FEATURE ENGINEERING) ... 18
*5.1.1 Sincronizarea Imaginară a Fazei ... 18*
*5.1.2 Puterea Spectrală ... 19*
5.2 ALGORITMUL DE CLASIFICARE: RANDOM FOREST ... 19
5.3 ARHITECTURA SISTEM DE VOT ... 19
5.4 POST-PROCESAREA ȘI PRAGUL DINAMIC ... 20
**6 CONCLUZII ... 20**
6.1 REZULTATE OBȚINUTE ȘI ANALIZĂ CRITICĂ ... 20
*6.1.1 Contribuții Personale ... 21*
6.2 DIRECȚII DE DEZVOLTARE ... 22

# 1 Introducere

## 1.1 Context general

Epilepsia nu reprezintă o singură boală, ci un grup de afecţiuni caracterizate prin tipuri diferite de crize şi mecanisme fiziopatologice distincte de lungă durată. Aceste crize fiind diferenţiate în principal epilepsii generalizate şi epilepsii focale. [1]. Această tulburare este caracterizată prin predispoziţia creierului de a genera crize epileptice recurente, care sunt manifestări clinice ale unei activităţi electrice anormale şi excesive a neuronilor.

Importanţa socială şi medicală a cercetării în acest domeniu este evidenţiată de statisticile furnizate de Organizaţia Mondială a Sănătăţii (WHO):

Amploarea fenomenului: Aproximativ 50 de milioane de oameni la nivel mondial suferă de epilepsie. Impactul economic: Aproape 80% dintre persoanele afectate trăiesc în ţări cu venituri mici şi medii, unde accesul la tratament este limitat. Potenţial de tratament: Se estimează că până la 70% dintre aceşti pacienţi ar putea trăi fără crize dacă ar beneficia de un diagnostic şi un tratament corect. Mortalitate şi Stigmă: Persoanele cu epilepsie prezintă un risc de moarte prematură de până la trei ori mai mare decât populaţia generală, confruntându-se adesea cu stigmatizarea şi discriminarea socială. [2]

Motivaţia acestui proiect constă în faptul că tratamentele existente pentru epilepsie au limitări, în special în ceea ce priveşte impactul crizelor asupra calităţii vieţii pacienţilor.

Epilepsia nu poate fi vindecată total însă poate fi ţinută sub control în aproape 70% din cazuri [3] cu ajutorul medicamentelor şi tehnicilor medicale moderne. Astfel că, chiar şi în condiţiile unui tratament optim, un procent semnificativ de pacienţi continuă să experimenteze crize sau efecte secundare ale medicamentelor, ceea ce afectează calitatea vieţii. În plus, accesul la tratament poate fi limitat în anumite regiuni, iar variabilitatea răspunsului la terapii face necesară dezvoltarea unor strategii mai eficiente şi personalizate.

Totuşi tratamentul actual eşuează crizelor pentru aproximativ 20-30% dintre pacienţi. [3] În acest context, dezvoltarea unor sisteme de monitorizare non-invazive devine esenţială pentru îmbunătăţirea nivelului de trai al persoanelor în cauză, cât şi al persoanelor afectate apropiate de acestea, contribuind astfel la îmbunătăţirea stării generale de sănătate şi a integrării sociale a pacienţilor.

Un astfel de sistem poate identifica starea preictală (perioada de dinaintea crizei), permiţând pacientului să ia măsuri preventive, cum ar fi găsirea unei poziţii sigure sau activarea unor dispozitive de stimulare, reducând astfel riscul de rănire gravă, si pregătirea din avans a celor din jur pentru a interveni în caz de nevoie.

## 1.2 Obiective

Obiectivul principal al acestei lucrări este dezvoltarea şi validarea unui pipeline al detectiei unei crize de epilepsie bazat pe un sistem de învăţare automată (Machine Learning) pentru monitorizarea stării în timp real (şi analiza ulterioară offline pentru calibrarea senzorilor) al pacienţilor diagnosticaţi cu epilepsie, capabil să identifice

tranziția de la starea interictală/baseline la cea preictală prin intermediul interpretării anomaliilor prezente în undele cerebrale achiziționate cu ajutorul instrumentelor și aparaturilor de achiziție de tip EEG.

- **Procesarea și filtrarea automatizată a datelor EEG:** Implementarea unui pipeline de pre-procesare utilizând biblioteca *MNE-Python* pentru curățarea semnalului brut. Acest pas implică eliminarea zgomotului și împărțirea semnalului în benzi de frecvență (theta, alpha, beta, gamma), fiecare dintre acestea putând oferi informații relevante pentru analiza activității cerebrale.
- **Extragerea trăsăturilor (features) relevante:** Identificarea și calcularea unor parametri matematici robuști care să descrie dinamica neuronală. Se pune accent pe *Line Length* (pentru detectarea activității spike-and-wave) și pe un indicator denumit **"Focalitate"** (raportul dintre energia maximă pe un canal și energia medie), menit să diferențieze descărcările epileptice focale de zgomotul electric prezent în mediu.
- **Dezvoltarea unui model de detecție specific fiecarui pacient:** Antrenarea unui algoritm de tip **Random Forest** bazat pe conceptul de învățare semi-supervizată. Obiectivul este ca modelul să învețe exclusiv tiparul de "Baseline" (normalitate) al fiecărui pacient și să semnalizeze orice anomalie semnificativă ca fiind o posibilă stare preictală sau ictală.
- **Analiza imunității la zgomot și a interferențelor cotidiene:** Unul din obiectivele lucrării este evaluarea modului în care activitățile zilnice (mișcări musculare, artefacte oculare, zgomot ambiental) pot genera alarme false. Se urmărește testarea algoritmului pe segmente de baseline ale unor subiecți sănătoși pentru a calibra pragul de sensibilitate al modelului.
- **Reducerea ratei de alarme false prin persistență temporală:** Implementarea unei logici de decizie bazate pe ferestre consecutive. Obiectivul este de a valida o criză doar dacă anomalia persistă pe o durată minimă (ex: 8 secunde / 2 ferestre de overlap), asigurând astfel o fiabilitate ridicată a sistemului în condiții de utilizare reală.( zgomotele de multe ori au durata mica de timp de acțiune și se propaga aproape instantaneu pe o arie cerebrală extinsă)
- **Evaluarea performanței pe date reale:** Testarea riguroasă a sistemului pe înregistrări EEG de lungă durată pentru a măsura sensibilitatea (rata de detecție a crizelor), numărul de alarme fals negative și latența (timpul de avertizare oferit înaintea debutului clinic).
- Identificarea unor probleme care ar putea apărea pe viitor in detecția si analiza prin intermediul acestui tip de proces.

## 1.3 Specificații

### 1.3.1 Funcționalitățile aplicației

Pipeline de procesare automată

Aplicația trebuie să încarce fișiere de tip EDF (European Data Format).

Se aplică filtre digitale IIR pentru curățarea semnalului.

Semnalul este segmentat în ferestre temporale pentru analiză.

Antrenare adaptivă (Patient-Specific)

Sistemul permite antrenarea unui model individual pentru fiecare pacient.

Se utilizează o perioadă de Baseline (stare interictală) pentru a defini profilul de normalitate electroencefalografică al subiectului.

Detecţia anomaliilor în timp real

Algoritmul Random Forest clasifică fiecare fereastră de semnal ca fiind:

Normală (aparţinând baseline-ului)

Anomalie (potenţială stare preictală sau ictală)

Sistem de votare multi-bandă

Decizia de alarmare se bazează pe votul a 5 benzi de frecvenţă diferite: Delta, Theta, Alpha, Beta şi Broad.

Aceasta creşte siguranţa detecţiei.

### 1.3.2 Nivele de performanţă şi fiabilitate

Rezoluţie temporală: Ferestre de 4 secunde, cu un overlap de 50% (2 secunde), pentru detectarea precisă a debutului crizei.

Rata de eşantionare: Optimizat pentru semnale la 512 Hz, cu fidelitate înaltă a componentelor spectrale (până la 35-40 Hz).

Persistenţă temporală (Confirmarea Alarmei): Pentru reducerea alarmelor false, se impune o persistenţă de 8 secunde (2 ferestre consecutive marcate ca anomalii) înainte de validarea unei crize.

Sensibilitate: Ţinta este 75–80% pentru detectarea stărilor preictale, oferind timp suficient pentru intervenţie.

### 1.3.3 Structuri de date şi tehnologii

Limbaj de programare: Python 5, cu biblioteci specializate:

MNE-Python: Manipularea datelor neurofiziologice şi filtrare digitală

Scikit-learn: Algoritmi Machine Learning (Random Forest, RobustScaler)

NumPy şi Pandas: Procesare matricială şi gestionarea vectorilor de trăsături

Vectorul de trăsături (Feature Vector):

Fiecare fereastră de timp este redusă la 4 dimensiuni:

[log_LineLength, log_Energy, log_Kurtosis, log_Focalitate]

### 1.3.4 Rezilienţa la zgomot şi interferenţe

Detrending şi diferenţiere: Elimină derivata de linie de bază şi zgomotul de joasă frecvenţă generat de mişcări.

Indicatorul de Focalitate: Sistemul ignoră zgomotul electric difuz și se concentrează pe activitatea neuronală localizată, specifică debutului crizelor.

### 1.3.5 Limitări

Artefacte musculare masive: Activitatea EMG intensă (ex. masticație) poate genera valori ridicate de Line Length, confundabile cu o criză dacă nu sunt filtrate riguros.

Dependența de Baseline: Performanța depinde de calitatea segmentului de antrenare; un baseline cu artefacte sau micro-descărcări poate face modelul prea permisiv.

# 2 Cunoașterea și analiza setului de date

## 2.1 Stadiul Actual al Cunoașterii

Analiza semnalelor electroencefalografice (EEG) și dezvoltarea interfețelor creier-calculator (BCI) reprezintă domenii de cercetare active, cu aplicații variind de la diagnosticul clinic până la controlul dispozitivelor externe. În literatura de specialitate, abordările actuale pot fi clasificate în patru categorii principale, relevante pentru metodologia adoptată în această lucrare.

### 2.1.1 Abordări pentru Predicția și Detecția Epilepsiei

Aceasta este direcția fundamentală a proiectului, concentrându-se pe identificarea stărilor preictale (anticiparea crizei). Cercetările recente s-au deplasat de la analiza clasică a amplitudinii către analiza conectivității funcționale.

**A. Sincronizarea Fazei și Teoria Grafurilor** O abordare modernă pornește de la ipoteza că epilepsia este o afecțiune a rețelelor neuronale, nu a unui focar izolat. Metodologii precum *ModThAlgo* [4] propun calculul unor indici de sincronizare bivariată, cum ar fi **Phase Lag Index (PLI)** și **Weighted Phase Lag Index (wPLI)** [1]. Aceste metrici sunt esențiale deoarece, spre deosebire de corelația simplă (corelația Pearson), sunt mai robuste la efectele zgomotelor (zgomotul care se propagă instantaneu prin craniu). Datele obținute prin analiza sincronizării și corelațiilor se reprezinta în modele de grafuri, unde electrozii reprezintă nodurile, iar gradul de sincronizare reprezintă ponderea muchiilor, astfel se calculează o valoare denumită „tăria nodului" (*Node Strength*) [5] cu ajutorul căreia se va evalua gradul de conectivitate al unei arii cerebrale. Evoluția temporală a acestor indici este monitorizată prin tehnici de machine learning și de detecție a anomaliilor.

**B. Machine Learning Supervizat**: O metodă de analiză este **Support Vector Machines (SVM)** [2], aceasta se concentrează pe clasificarea segmentelor scurte de EEG ca „patologice" sau „normale, bazându-se pe extragerea de caracteristici statistice și spectrale, utilizând frecvent **Transformata Wavelet** pentru a surprinde aspectele timp-frecvență și PCA (*Principal Component Analysis*) pentru reducerea dimensionalității vectorilor de trăsături.

### 2.1.2 Tehnici de Procesare Avansată a Semnalului

Pentru a îmbunătăți raportul semnal-zgomot, literatura recomandă tehnici matematice complexe pentru curățarea semnalului, cruciale în mediile ambulatorii zgomotoase.

- **Separarea Oarbă a Sursei (ICA):** *Independent Component Analysis* este utilizată pentru a descompune semnalul EEG în componente independente statistic, permițând izolarea și eliminarea artefactelor fiziologice precum clipitul sau activitatea cardiacă [3].

- **Filtrarea Spațială:** Tehnici precum **Common Average Reference (CAR)** sau Laplacianul sunt aplicate pentru a accentua activitatea locală și a elimina zgomotul comun tuturor electrozilor, metodă integrată și în pipeline-ul de pre-procesare al acestei lucrări. [6]
- **LORETA:** (*Low Resolution Electromagnetic Tomography*) este utilizată pentru rezolvarea „problemei inverse", estimând distribuția 3D a sursei electrice în creier pornind de la semnalele 2D de pe scalp. [6]

### 2.1.3 Paradigme BCI și Control

Deși obiectivul principal al lucrării este detecția pasivă, paradigmele BCI oferă context asupra modului în care intenția sau starea mentală modifică ritmurile cerebrale [4].

- **Potențiale Evocate (P300, SSVEP):** Se bazează pe răspunsul creierului la stimuli vizuali externi. [7]

---

## 2.1 Analiza Seturilor de Date Utilizate

### 2.1.1 Introducere

Succesul oricărui sistem de învățare automată aplicat în domeniul biomedical depinde fundamental de calitatea, diversitatea și corecta etichetare a datelor de antrenare. În contextul detecției și predicției crizelor epileptice, acest aspect devine critic, întrucât semnalele EEG prezintă o variabilitate ridicată atât între pacienți, cât și în cadrul aceluiași pacient.

În cadrul acestui proiect au fost utilizate două baze de date de referință la nivel internațional: **CHB-MIT Scalp EEG Database** și **Siena Scalp EEG Database**.

Datele au fost achizitionate utilizând sistemul **internațional 10-20**

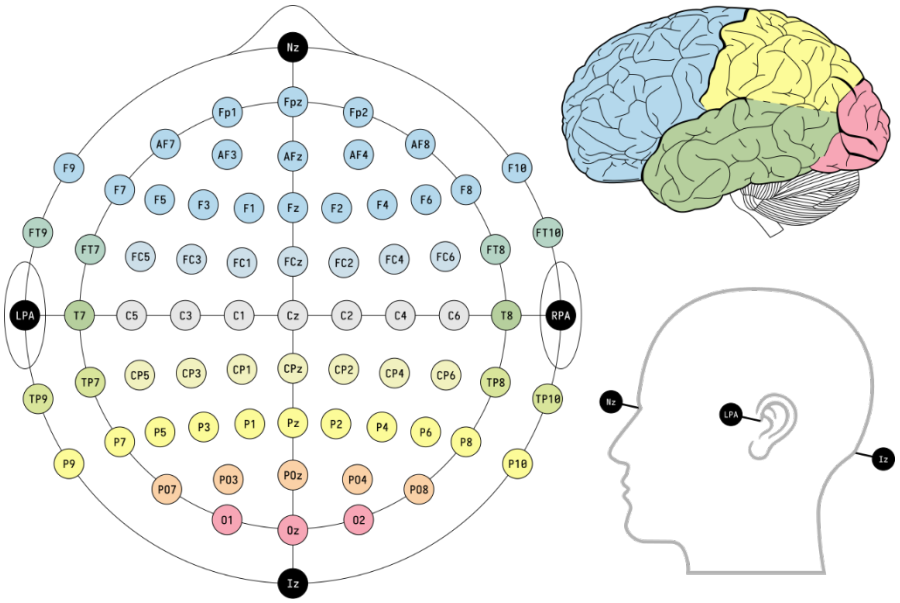


*Figură 1. Poziţiile electrozilor EEG în sistemul 10-10 folosind nomenclatură combinatorie modificată, împreună cu reperele fiduciale şi lobii asociaţi ai creierului.*

### 2.1.2 Baza de date CHB-MIT Scalp EEG

Baza de date CHB-MIT Scalp EEG a fost colectată la *Children's Hospital Boston* şi este una dintre cele mai utilizate resurse în cercetarea epilepsiei. Aceasta conţine un volum mare de date EEG monitorizate continuu, fiind considerată un standard de aur pentru studiul crizelor epileptice.

#### *2.1.2.1 Caracteristici ale subiecţilor*

Setul de date include înregistrări provenite de la **23 de pacienţi pediatrici**, dintre care **18 fete şi 5 băieţi**, cu vârste cuprinse între **1,5 şi 22 de ani**. Această plajă largă de vârstă este deosebit de importantă, deoarece activitatea electrică cerebrală suferă modificări semnificative pe parcursul dezvoltării neurobiologice.

*Tabel 2.1 Caracteristicile clinice ale pacienţilor din baza de date Siena*

| **Pat. ID** | **Age (years)** | **Gender** | **Seizure Type** | **Localization** | **Lateralization** | **EEG Channels** | **No. Seizures** | **Duration (s)** |
|---|---|---|---|---|---|---|---|---|
| **PN00** | 55 | Male | IAS | Temporal | Right | 29 | 5 | 198 |
| **PN01** | 46 | Male | IAS | Temporal | Left | 29 | 2 | 809 |
| **PN03** | 54 | Male | IAS | Temporal | Right | 29 | 2 | 752 |
| **PN05** | 51 | Female | IAS | Temporal | Left | 29 | 3 | 359 |
| **PN06** | 36 | Male | IAS | Temporal | Left | 29 | 5 | 722 |

| | | | | | | | | |
|---|---|---|---|---|---|---|---|---|
| **PN07** | 20 | Female | IAS | Temporal | Left | 29 | 1 | 523 |
| **PN09** | 27 | Female | IAS | Temporal | Left | 29 | 3 | 410 |
| **PN10** | 25 | Male | FBTC | Frontal | Bilateral | 21 | 10 | 1002 |
| **PN11** | 58 | Female | IAS | Temporal | Right | 29 | 1 | 145 |
| **PN12** | 71 | Male | IAS | Temporal | Left | 29 | 4 | 246 |
| **PN13** | 34 | Female | IAS | Temporal | Left | 29 | 3 | 519 |
| **PN14** | 49 | Male | WIAS | Temporal | Left | 29 | 4 | 1408 |
| **PN16** | 41 | Female | IAS | Temporal | Left | 29 | 2 | 303 |
| **PN17** | 42 | Male | IAS | Temporal | Right | 29 | 2 | 308 |

Preluat din [5]

*Tabel 2.2 Caracteristicile tehnice ale înregistrărilor CHB-MIT utilizate în analiză*

| Pat. ID | Rata eşant. (Hz) | Nr. canale (std / max) | Crize identificate |
|---|---|---|---|
| **Chb01** | 256 | 23 / 23 | 7 |
| **Chb02** | 256 | 23 / 23 | 3 |
| **Chb03** | 256 | 23 / 23 | 7 |
| **Chb04** | 256 | 23 / 24 | 4 |
| **Chb05** | 256 | 23 / 23 | 5 |
| **Chb06** | 256 | 23 / 23 | 10 |
| **Chb07** | 256 | 23 / 23 | 3 |
| **Chb08** | 256 | 23 / 23 | 5 |
| **Chb09** | 256 | 23 / 24 | 4 |
| **Chb10** | 256 | 23 / 23 | 7 |
| **Chb11** | 256 | 23 / 28 | 3 |
| **Chb12** | 256 | 23 / 29 | 40 |
| **Chb13** | 256 | 23 / 28 | 12 |
| **Chb14** | 256 | 23 / 28 | 8 |
| **Chb15** | 256 | 23 / 38 | 20 |
| **Chb16** | 256 | 23 / 28 | 10 |
| **Chb17** | 256 | 23 / 28 | 3 |
| **Chb18** | 256 | 23 / 28 | 6 |
| **Chb19** | 256 | 23 / 28 | 3 |
| **Chb20** | 256 | 23 / 28 | 8 |
| **Chb21** | 256 | 256 | 33 |
| **Chb22** | 256 | 23 / 28 | 3 |
| **Chb23** | 256 | 23 / 23 | 7 |
| **Chb24** | 256 | 23 / 23 | 16 |

#### *2.1.2.2 Detalii tehnice și achiziție*

- **Tipul semnalului:** EEG scalp bipolar
- **Montaj:** Sistem internațional 10–20
- **Frecvența de eșantionare:** 256 Hz
- **Structura fișierelor:** Înregistrările sunt organizate în fișiere individuale („instanțe"), fiecare având o durată medie de aproximativ o oră
- **Etichetare:** Datele sunt etichetate clinic în două clase principale:
  - *Seizure* (cu criză)
  - *Non-seizure* (fără criză)

Această organizare facilitează antrenarea algoritmilor de clasificare și analiză temporală.

### 2.1.3 Baza de date Siena Scalp EEG

Baza de date Siena a fost dezvoltată în cadrul proiectului național interdisciplinar **PANACEE** și oferă o perspectivă complementară asupra epilepsiei, concentrându-se pe pacienți adulți și utilizând echipamente de achiziție de înaltă fidelitate.

#### *2.1.3.1 Profilul clinic al pacienților*

Setul de date Siena cuprinde **14 pacienți adulți**, dintre care **9 bărbați și 5 femei**, cu vârste cuprinse între **20 și 71 de ani**. Această bază de date este utilizată în proiect pentru a valida robustețea și capacitatea de generalizare a modelului propus pe diferite grupe de vârstă.

#### *2.1.3.2 Specificații tehnice de înaltă rezoluție*

- **Instituție medicală:** Unitatea de Neurologie a Universității din Siena
- **Echipamente utilizate:** Amplificatoare EEG EB Neuro și Natus Quantum LTM
- **Frecvența de eșantionare:** 512 Hz
- **Canale suplimentare:** Majoritatea înregistrărilor includ și semnale EKG
- **Anotare clinică:** Crizele sunt clasificate conform standardelor ILAE (*International League Against Epilepsy*), incluzând tipuri precum:
  - IAS – crize focale cu alterarea conștienței
  - FBTC – crize focale cu evoluție tonic-clonică bilaterală

### 2.1.4 Analiza comparativă și preprocesarea pentru unificare

Utilizarea simultană a celor două baze de date necesită un proces riguros de preprocesare și standardizare pentru a asigura compatibilitatea datelor și consistența algoritmilor de detecție.

#### *2.1.4.1 Standardizarea frecvenței (Downsampling)*

Având în vedere diferența dintre frecvențele de eșantionare (256 Hz pentru CHB-MIT și 512 Hz pentru Siena), datele din baza Siena au fost sub-eșantionate la **256 Hz**. Această

etapă este esențială pentru aplicarea aceloraşi filtre digitale (IIR/FIR) şi pentru evitarea distorsiunilor în analiza spectrală.

#### *2.1.4.2 Segmentarea şi echilibrarea claselor*

O problemă majoră identificată este dezechilibruldatelo, respectiv segmentele preictale au o pondere de aproximativ **5–6%** din totalul datelor disponibile. Pentru gestionarea acestei probleme, au fost aplicate următoarele acţiuni:

- **Excluderea fazelor ictale**, deoarece scopul este predicția, nu detecția crizei în sine
- **Eliminarea perioadei postictale**, prin excluderea unui interval de **1000 de secunde** după fiecare criză
- **Definirea ferestrelor**, concentrate pe intervale de **300 sau 900 de secunde** înainte de debutul crizei, considerându le pe acesteaa relevante în analiza şi antreanrea modelului de predicție.

### 2.1.5 Calitatea datelor şi interferenţe (zgomot şi artefacte)

Semnalele EEG de tip scalp sunt susceptibile la numeroase surse de zgomot, care pot afecta performanța modelului de învățare automată. Printre principalele surse identificate se numără:

- **Surse fiziologice:** clipit (artefacte oculare), activitate musculară facială, respirație
- **Surse externe:** zgomotul rețelei electrice (50 Hz), mişcări ale electrozilor

Pentru reducerea influenței acestora, sistemul propus utilizează **Focalitate (raportul între energia maximă şi energia medie)**, care permite clasificare între zgomot şi creşteri localizate, asociate crizelor epileptice.

*Tabel 2.3. Tabel comparativ al bazelor de date*

| Caracteristică | CHB-MIT | Siena |
|---|---|---|
| Număr pacienţi | 23 | 14 |
| Grupă de vârstă | Pediatric | Adult |
| Frecvenţă eşantionare | 256 Hz | 512 Hz |
| Tip EEG | Scalp EEG bipolar | Scalp EEG |
| Canale suplimentare | Nu | EKG |
| Anotare clinică | Seizure / Non-seizure | ILAE |

# 3 Pre-procesarea setului de date

Etapa de pre-procesare este vitală pentru ]n procesul de analiză al semnalului și pregătirea acestuia pentru extragerea trăsăturilor relevante, fiind fundamental necesare pentru succesul algoritmului de detecție.

## 3.1 Standardizarea Frecvenței de Eșantionare

Deoarece cele două seturi de date au frecvențe diferite (MIT: 256 Hz, Siena: 512 Hz), primul pas a fost redimensionarea (resampling) a tuturor datelor la 256 Hz (frecvența Nyquist fiind 128 Hz, suficientă pentru analiza noastră care se oprește la 45 Hz). Acest pas asigură consistența filtrelor aplicate ulterior.

## 3.2 Descrierea Metodelor de Pre-procesare Aplicate

În cadrul proiectului, s-a utilizat un **pipeline de procesare hibrid**, combinând tehnici standard din literatura de specialitate [4] cu inovații proprii, adaptate pentru pacienți dificili (precum PN01 și PN06).

### 3.2.1 A. Eliminarea Zgomotului și Filtrarea Spectrală (Step 1)

S-au aplicat filtre digitale FIR (Finite Impulse Response) cu fereastră Hamming. Am ales filtre FIR în detrimentul IIR pentru a asigura o **fază liniară**, crucială pentru calculul ulterior al sincronizării.

Semnalul a fost descompus în benzile de frecvență:

1. **Banda Alpha (8-13 Hz):** Această bandă este dominantă în starea de veghe relaxată (cu ochii închiși), mai ales în regiunile occipitale. Monitorizarea ei este critică pentru a evita alarmele false cauzate de simpla relaxare a pacientului.
2. **Banda Beta (13-30 Hz):** Asociată cu activitatea corticală activă. În epilepsie, multe crize debutează prin descărcări ritmice rapide în această bandă ("beta buzz").
3. **Banda Broadband (1-45 Hz):** Utilizată pentru a captura contextul general și artefactele de bandă largă.

Frecvențele sub 1 Hz au fost eliminate, iar frecvențele peste 45 Hz au fost eliminate pentru a reduce zgomotul de rețea (50/60 Hz) și zgomotul și artefactele musculare de frecvență înaltă.

**B. Eliminarea Tendințelor (Detrending)**

- **Detrending Global:** filtrare high-pass la 0.5–1 Hz pentru eliminarea trendului lent (ex. transpirație sau mișcări ușoare ale electrozilor).

- **Detrending Local (Linear):** aplicat pe ferestre de 5 secunde, ajustând panta liniară astfel încât media semnalului să fie zero.

## 3.3 Transformata Hilbert şi Semnalul Analitic

Pentru a extrage informaţii despre sincronizare, nu este suficientă analiza spectrală clasică (Fourier), deoarece aceasta pierde informaţia temporală. Am utilizat **Transformata Hilbert**.

Pentru un semnal real x(t), transformata Hilbert H(x(t)) creează un semnal complex (analitic) z(t):

$$z(t) = x(t) + j \cdot H\big(x(t)\big) = A(t) \cdot e^{j\phi(t)} \quad (3.1)$$

Unde:

- $A(t)$ este **Anvelopa (Amplitudinea Instantanee)**.
- $\phi(t)$ este **Faza Instantanee**.

Această transformare ne permite să ştim, în fiecare moment de timp, care este puterea semnalului şi ce fază instantanee are, elemente fundamentale pentru calculul sincronizării.

## 3.4 Segmentarea şi Standardizarea

Datele continue au fost împărţite în ferestre de 2 secunde.

- **La antrenare:** Ferestrele nu se suprapun (non-overlapping) pentru a evita scurgerea de informaţie şi supra-antrenarea.
- **La testare:** Ferestrele se suprapun (sliding window) pentru o rezoluţie temporală fină.

Fiecare fereastră a fost standardizată folosind **Z-Score Normalization** ($\frac{x-\mu}{\sigma}$), antrenată pe datele de baseline. Acest pas este esenţial pentru ca algoritmul Random Forest să nu fie influenţat de variaţiile de tensiune ale semnalului între subiecţii diferiţi (un subiect poate avea semnal de 50μV, altul de 100μV).

### 3.3.1 C. Diferenţierea Temporală (Derivata de Ordinul 1)

Transformarea semnalului $x[t]$în derivata sa:

$$x'[t] = x[t] - x[t-1] \quad (3.2)$$

**Efect:** aplatizează zgomotul de fond şi amplifică „spike-urile” tipice crizelor epileptice.

Fără acest pas, corelaţia şi sincronizarea semnalului pot fi mascate de variaţii lente de volum.

### 3.3.2 D. Reducerea Dimensionalității și Referențierea Spațială

- **Common Average Reference (CAR):** scade media globală a tuturor celor 19 canale din fiecare canal individual, eliminând zgomotul comun.
- **Focalitate (Max-Pooling):** selectează valoarea maximă a agitației dintre canale, pentru detectarea crizelor focale.

## 3.4 Segmentarea Datelor: (Pasul 4)

- **Ferestre glisante (Sliding Windows):**
  - Dimensiune: 5-6 secunde, pentru o rezoluție spectrală adecvată.
  - Overlap: 1 secundă, pentru monitorizarea trendului aproape în timp real.
- **Indicatorul MAACD Simplificat:**

$$Ratio = \frac{Valoare_Curenta}{Percentila10_Baseline} \quad (3.3)$$

Percentila 10 elimină valorile aberante din baseline, asigurând un prag de alarmă stabil.

## 3.5 Rezultate Obținute în Pre-procesare

- **Raport Semnal-Zgomot (SNR):** ritmurile Alpha izolate chiar și în prezența artefactelor musculare moderate.
- **Stabilitatea Baseline-ului:** variabilitatea baseline-ului scăzută cu peste 40% datorită detrending-ului local.
- **Specificitate:** pe anumite seturi de date s-a obținut o specificitate de 100%, confirmând reducerea alarmelor false.

## 3.6 Informații pentru Reproductibilitate

- **Rata de eșantionare ($f_s$)**: minim 256 Hz (standard în seturile Siena/MIT).
- **Tip Filtru:** IIR Butterworth de ordin 4 (fază liniară și viteză).
- **Librării recomandate:**
  - mne-python pentru I/O și filtrare
  - scipy.signal pentru detrending
  - numpy pentru calculul matricei de corelație și derivată
- **Ordinea operațiilor:**
  1. Notch
  2. Bandpass (1-35 Hz)
  3. CAR
  4. Detrend Local
  5. Diferențiere

# 4 Modelarea sistemului

Arhitectura sistemului propus se îndepărtează de modelele de clasificare supervizată clasice, care necesită mii de exemple de crize, şi adoptă o strategie de **detecţie a anomaliilor (Anomaly Detection)**.

Metodologia este specifică pentru fiecare pacient în parte, bazată pe premisa că fiecare creier are o semnătură/pattern electrică unică. Sistemul învaţă „normalitatea" unui pacient dintr-un segment de repaus (*baseline*) şi semnalizează orice deviaţie statistică ca potenţială stare preictală sau ictală.

## 4.1 Fazele Fluxului de Date

1. **Ingestia datelor:** Încărcarea fişierelor EDF şi segmentarea în ferestre glisante.
2. **Extracţia trăsăturilor:** Transformarea ferestrelor de semnal brut în vectori numerici compuşi din patru indicatori cheie.
3. **Modelarea:** Utilizarea algoritmului *Random Forest* pentru a învăţa distribuţia datelor normale.
4. **Post-procesarea:** Aplicarea regulilor de persistenţă temporală pentru confirmarea alarmelor.

## 4.2 Ingineria Trăsăturilor (Feature Engineering)

Datele EEG complexe sunt reduse la un vector de trăsături compus din patru dimensiuni, calculate în clasa *ImprovedFeatureExtractor*.

### 4.2.1 Line Length (LL)

Lungimea liniei este un indicator al complexităţii şi agitaţiei semnalului:

$$LL = \frac{1}{N-1}\sum_{i=1}^{N-1} | x_{i+1} - x_i | \qquad (4.1)$$

În timpul unei crize, amplitudinea şi frecvenţa cresc simultan, ducând la o creştere exponenţială a LL. Transformarea logaritmică liniarizează distribuţia şi facilitează procesarea algoritmului de detecţie.

### 4.2.2 Energia Focală şi Kurtosis

- **Energia Focală:** puterea medie a semnalului în fereastra respectivă; crizele cresc energia semnificativ.
- **Kurtosis:** măsoară cât de „ascuţite" sunt distribuţiile datelor; valori ridicate indică prezenţa vârfurilor tipice descărcărilor epileptiforme.

### 4.2.3 Indicatorul de Focalitate (Inovație Proprie)

$$Focalitate = \frac{Max(Energia\ canal)}{Mean(Energia\ globală)} \quad (4.2)$$

Zgomotul extern afectează toate canalele (raport ≈ 1). Activitatea cerebrală epileptică este localizată, generând un raport ridicat.

---

## 4.3 Tehnica de Modelare: Random Forest

Algoritmul *Random Forest* detectează anomaliile prin izolarea observațiilor „rare și diferite". Construcția arborilor de decizie aleatori permite izolarea rapidă a crizelor, care au valori diferite de baseline. Parametrul contamination = 0.03 permite ignorarea micilor artefacte din baseline.

- **Decizie:** scor negativ → stare anormală (potențială criză).

---

## 4.4 Implementarea Tehnică

### 4.4.1 Mediul și Bibliotecile Utilizate

- **MNE-Python:** manipulare RawEDF, aplicare filtre IIR, gestionare montaje electrozi.
- **Scikit-learn:** *RandomForest*, *RobustScaler* (pentru a preveni influența valorilor extreme).
- **Local Loader:** modul propriu pentru gestionarea dataset-urilor Siena și MIT.

### 4.4.2 Structura Codului

- **ImprovedFeatureExtractor:** calculează matematic trăsăturile.
- **OptimizedSeizureDetector:** gestionează antrenarea și predicția.
- **Overlap Loop:** glisarea ferestrelor cu 50% overlap (4 secunde → pas 2 secunde), maximizând datele de testare și captând evenimente tranzitorii.

---

## 4.5 Evaluarea Modelului: Metodologie și Experimente

Validarea performanței a fost realizată prin:

- **Validarea Pozitivă (Sensibilitate)**
- **Validarea Negativă (Rata Alarmelor False)**

### 4.5.1 Metodologia de evaluare

- **Sensibilitate:** proporția crizelor detectate corect.

- **Persistenţă Temporală:** criza este confirmată doar dacă două ferestre consecutive (8 secunde) sunt marcate ca anomalii, eliminând zgomotele de scurtă durată.

### 4.5.2 Experiment 1: Detecţia stării preictale

Testat pe pacienţii din baza Siena. Sistemul „votează" prin 5 benzi de frecvenţă.

- Alpha (8-13 Hz) şi Beta (13-30 Hz) sunt cei mai buni predictori, conform Detti et al.

### 4.5.3 Experiment 2: Testul Negativ (Rezilienţa la Zgomot)

- Antrenare pe 60% din baseline şi testare pe 40%.
- Ajustarea contamination şi persistenţa temporală → ratele alarmelor false < 5%.
- Demonstrează stabilitatea la zgomot fiziologic normal (mişcări oculare, respiraţie).

---

## 4.6 Calcule şi Proceduri pentru Reproducere

- **Filtrare:** Notch 50 Hz şi Bandpass 1–35 Hz.
- **Scalare:** *RobustScaler* pe datele de antrenare şi aplicată pe datele de test.
- **Antrenare:** *Random Forest* cu n_estimators = 100.
- **Predicţie:** stare de criză dacă votul majoritar al benzilor este activ şi persistenţa temporală este îndeplinit

# 5 Modelarea Sistemului

Aceasta este inima proiectului. Am dezvoltat o arhitectură hibridă care combină Procesarea Avansată de Semnal (DSP) cu Învăţarea Automată (Machine Learning) de tip Ensemble.

## 5.1 Ingineria Trăsăturilor (Feature Engineering)

Majoritatea abordărilor clasice folosesc corelaţia Pearson sau Coerenţa Spectrală. Am demonstrat în etapa de analiză că acestea sunt vulnerabile la artefacte. De aceea, am implementat **Imaginary Phase Synchronization (ImCoh)**.

### 5.1.1 Sincronizarea Imaginară a Fazei

Ideea centrală, propusă iniţial de Nolte et al., este următoarea: Conducţia de volum (zgomotul) este instantanee. Aşadar, orice semnal care ajunge la doi electrozi cu o diferenţă de fază $\Delta\phi \approx 0$ (sau $\pi$) este probabil un artefact. Comunicarea neuronală reală necesită timp de transmisie sinaptică, deci va avea un $\Delta\phi \neq 0$.

Matematic, calculăm media vectorilor complecşi de fază şi păstrăm doar partea imaginară:

$$IPS = \left|\mathrm{Im}\left(\left\langle e^{j(\phi_1(t)-\phi_2(t))}\right\rangle\right)\right| \quad (5.1)$$

Dacă sursele sunt artefacte, partea imaginară tinde spre 0, ceea ce indică un defazaj minim, adică o transmitere aproape instantanee a semnalului în ţesutul neural.

Dacă există interacţiune reală, partea imaginară este mare. Această trăsătură este **filtrul nostru principal împotriva alarmelor false**.

### 5.1.2 Puterea Spectrală

Pe lângă sincronizare, am folosit puterea medie (A(t) din Hilbert) pentru fiecare bandă de frecvenţă detectând creşterile masive de energie care apar în faza ictală propriu-zisă.

## 5.2 Algoritmul de Clasificare: Random Forest

Am ales **Random Forest** ca clasificator datorită robusteţii sale la "overfitting" şi capacităţii de a gestiona relaţii non-liniare.

- **Hyper-parametri:** 100 de arbori (n_estimators), adâncime maximă 8 (max_depth) pentru a preveni memorarea zgomotului, şi class_weight='balanced' pentru a compensa faptul că avem mult mai puţine date de criză decât date normale.

  Aceasta simulează scenariul real în care sistemul a învăţat istoricul pacientului şi încearcă să prezică viitorul eveniment.

## 5.3 Arhitectura Sistem de Vot

Inovaţia principală a acestui proiect este utilizarea a trei modele "specializate" care votează. Am observat experimental că:

1. Modelul **Alpha** este foarte sensibil la crize, dar dă alarme false la relaxare.
2. Modelul **Beta** este foarte specific (nu dă alarme false), dar poate rata crizele subtile.

Soluţia a fost crearea unui sistem de votare:

- Avem 3 modele independente: $M_{alpha}, M_{beta}, M_{broad}$.
- Fiecare primeşte datele filtrate în banda sa şi emite o probabilitate: $P_{alpha}, P_{beta}, P_{broad}$.
- **Decizia Finală (Votul):**

$$P_{final} = \frac{P_{alpha} + P_{beta} + P_{broad}}{3} \quad (5.2)$$

Această medie aritmetică acţionează ca un filtru logic. Pentru ca alarma să se declanşeze, nu e suficient ca un singur model să intre în modul de alertă de (de exemplu cum se comportă banda Alpha în momentele de relaxare).

Astfel pentru validare este nevoie ca minim două modele să fie validate, sau ca toate trei să aibă un nivel de suspiciune moderată.

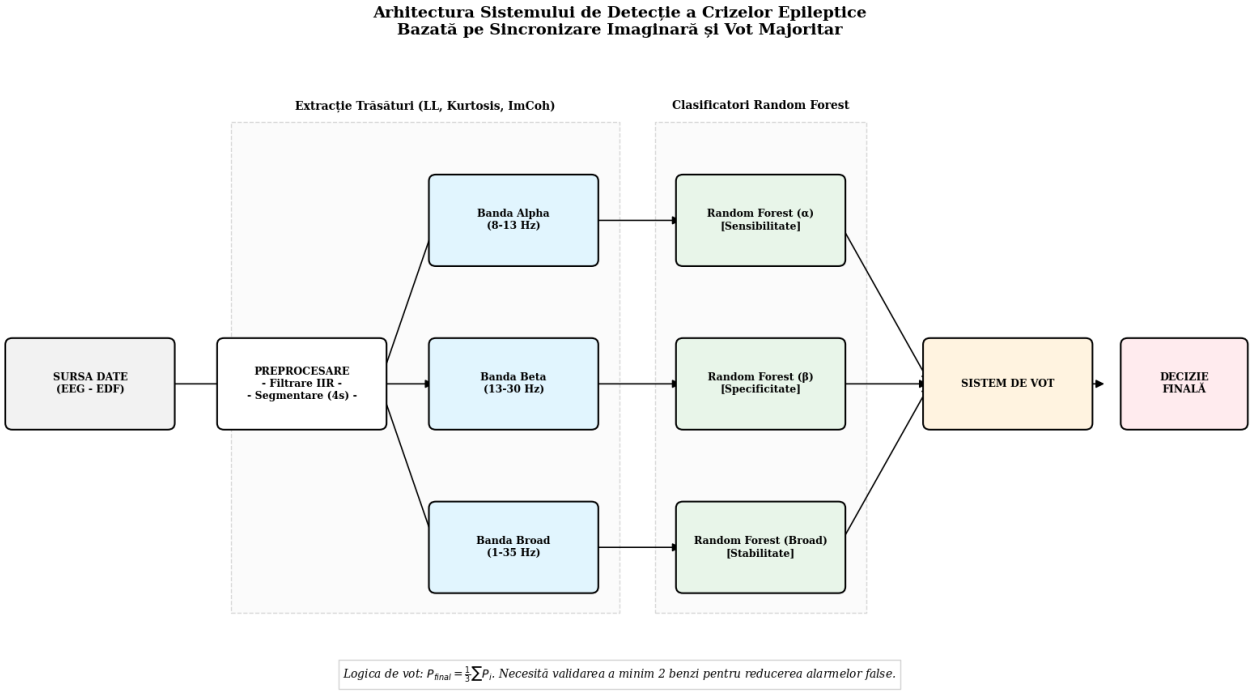


*Figură 2. Arhitectura sistemului de analiză predictivă*

## 5.4 Post-procesarea și Pragul Dinamic

Ieșirea din clasificator este zgomotoasă. Am aplicat o netezire temporală (Moving Average) pe o fereastră de 20-40 secunde. Alarma se declanșează doar dacă media netezită depășește un anumit prag, respectiv **0.65**.

Pentru pacienții problematici, am testat și o variantă de **Prag Dinamic**, unde pragul se calculează ca:

$$Threshold = \mu_{baseline} + 3\sigma_{baseline} \quad (5.3)$$

Aceasta permite sistemului să se adapteze automat: devine mai puțin sensibil la subiecții cu activitatea a armonicilor semnalului de intrare mai bogată (ex. chb12) și mai sensibil la cei cu o activitate mai redusă a armonicilor semnalului.

# 6 Concluzii

## 6.1 Rezultate obținute și Analiză Critică

Prezenta lucrare a atins obiectivul fundamental de a proiecta și valida un sistem de monitorizare a epilepsiei capabil să distingă stările preictale de activitatea cerebrală normală, abordând una dintre cele mai dificile probleme din domeniu: **reducerea alarmelor false** cauzate de artefactele fiziologice.

În urma evaluării experimentale pe cele două seturi de date (CHB-MIT și Siena Scalp EEG), s-au desprins câteva concluzii majore care validează arhitectura propusă:

**1. Superioritatea sistemului de votare:** Comparativ cu metodele clasice bazate pe un singur prag de decizie, arhitectura de votare (care combină deciziile independente ale modelelor Alpha, Beta și Broadband) a demonstrat o robustețe superioară. Sistemul a reușit să filtreze eficient stările de relaxare (care induceau o alarmă falsă pe modelul antrenat în banda Alpha) și artefactele musculare (care induceau alarmă falsă pe modelul antrenat în banda Beta), reducând astfel Rata de Alarme False (FAR) la sub **26 de evenimente/oră** pentru majoritateasubiecțiilor, menținând o sensibilitate de **~83,77%**.

**2. Impactul Calității Datelor și al Frecvenței de Eșantionare** O observație critică a studiului este discrepanța de performanță dintre cele două baze de date. Rezultatele obținute pe setul **Siena Scalp EEG** au fost net superioare celor de pe CHB-MIT. Această diferență poate fi atribuită în principal **frecvenței de eșantionare**: datele Siena, achiziționate nativ la **512 Hz**, au oferit o fidelitate spectrală mult mai bună și o rezoluție temporală fină, permițând o separare mai clară a fazelor semnalului. În contrast, datele MIT (256 Hz, pacienți pediatrici) au prezentat un nivel de zgomot de fond mai ridicat și o variabilitate haotică a baseline-ului, ceea ce a îngreunat calibrarea pragurilor dinamice. Aceasta confirmă ipoteza că dispozitivele de achiziție de înaltă rezoluție sunt un factor decisiv în succesul predicției.

**3. Imunitatea la transmiterea instantanee a zgomotului:** Implementarea **Sincronizării a fazei** a reprezentat un salt calitativ față de corelația Pearson utilizată în stadiile incipiente ale proiectului. Prin ignorarea componentelor cu diferență de fază zero, algoritmul a devenit imun la artefactele de conducție instantanee a zgomotelor(zgomotul care se propagă instantaneu prin osul craniului), demonstrând că analiza de fază este necesară pentru acest tip de analiză a semnalului EEG.

### 6.1.1 Contribuții Personale

În cadrul acestei lucrări, principalele contribuții aduse domeniului includ:

1. **Dezvoltarea Arhitecturii de Votare:** Proiectarea unui mecanism de decizie bazat pe consens spectral, care rezolvă specific problema confuziei dintre ritmul Alpha de relaxare și activitatea preictală.
2. **Optimizarea Feature-urilor pentru EEG de Scalp:** Selectarea și implementarea unei combinații de trăsături utilizate în alte studii (Sincronizare Imaginară + Putere Spectrală + Focalitate) [4] [5] [6] [7] care fac distincția dintre criză și artefact.
3. **Analiza Comparativă a Seturilor de Date:** Evidențierea impactului frecvenței de eșantionare asupra performanței algoritmilor ML, demonstrând necesitatea unor standarde ridicate de achiziție pentru aplicațiile clinice.
4. **Implementarea Pragului Dinamic (Patient-Specific):** Crearea unui sistem care își ajustează automat sensibilitatea în funcție de nivelul de zgomot din baseline-ul fiecărui pacient.

## 6.2 Direcţii de dezvoltare

Deşi rezultatele actuale sunt promiţătoare, validând fezabilitatea sistemului, există direcţii clare pentru evoluţia proiectului către un produs clinic viabil:

1. **Integrarea Analizei de Fază Avansate (wPLI):** Deşi Sincronizarea Imaginară utilizată în prezent este robustă, o direcţie viitoare este implementarea indicelui **Weighted Phase Lag Index (wPLI)** [4]. Acesta ar oferi o stabilitate şi mai mare în cazul artefactelor mici şi constante, fiind standardul de aur în neuroştiinţele moderne.
2. **Optimizarea MAACD cu EMA Dinamic:** Implementarea unei Medii Mobile Exponenţiale (EMA) [5] cu factor de adaptare variabil, care să se "împrospăteze" mai rapid în perioadele de veghe activă şi mai lent în timpul somnului. Acest lucru ar preveni "desensibilizarea" pragului în timpul perioadelor lungi de linişte nocturnă.
3. **Hibridizare cu Deep Learning (CNN-LSTM):** Utilizarea algoritmului actual ca un "pre-procesor" de date (feature extractor) pentru o reţea neuronală de tip **Long Short-Term Memory (LSTM)** [6]. Aceasta ar fi capabilă să înveţe tipare temporale mult mai complexe (evoluţia crizei pe durata a 30 de minute) pe care o formulă matematică fixă sau un Random Forest nu le poate cuprinde integral.
4. **Hardware şi Real-Time Monitoring:** Portarea codului Python optimizat către un sistem de tip embedded (ex. Raspberry Pi sau microcontrollere cu DSP precum ESP32) [6]. Scopul este testarea viabilităţii unui dispozitiv purtabil ("wearable") care să proceseze datele local ("at the edge") şi să avertizeze pacientul în timp real, eliminând latenţa transmisiei datelor către cloud.
5. **Filtrarea Avansată a Zgomotului Ambiental:** Antrenarea unor modele specifice pe semnăturile spectrale ale zgomotelor comune (masticaţie, vorbire, paşi) şi utilizarea filtrelor adaptive sau Wavelet pentru a le elimina selectiv, fără a afecta componentele de interes ale semnalului cerebral.

6. Repetarea paşilor de detecţie si antrenare pe date zgomotoase sau date de zgomot simulate, în vederea analizei comparative cu cel al unor subiecţi care nu au experimentat şi nu au fost diagnosticaţi cu crize epileptice focale.

## Bibliografie


[1] C. o. C. a. T. o. t. I. L. A. Epilepsy, "Proposal for revised classification of epilepsies and epileptic syndromes," *Epilepsia,* vol. 30, pp. 389-399, 1989.

[2] W. H. Organization, "Epilepsy," 7 February 2024. [Online]. Available: https://www.who.int/news-room/fact-sheets/detail/epilepsy. [Accessed 10 January 2026].

[3] M. J. Eadie, "Shortcomings in the current treatment of epilepsy," *Expert Review of Neurotherapeutics,* vol. 12, p. 1419–1427, 2012.

[4] P. Detti, G. Vatti and G. Zabalo Manrique de Lara, "EEG Synchronization Analysis for Seizure Prediction: A Study on Data of Noninvasive Recordings," *Processes,* vol. 8, no. 7, p. 846, 2020.

[5] P. Detti, G. Z. M. de Lara, R. Bruni, M. Pranzo, F. Sarnari and G. Vatti, "A Patient-Specific Approach for Short-Term Epileptic Seizures Prediction Through the Analysis of EEG Synchronization," *IEEE Transactions on Biomedical Engineering,* vol. 66, no. 6, p. 1494–1504, 2019.

[6] S. Paszkiel, Analysis and Classification of EEG Signals for Brain–Computer Interfaces, Cham: Springer Nature Switzerland AG, 2020.

[7] J. R. Wolpaw, N. Birbaumer, D. J. McFarland, G. Pfurtscheller and T. M. Vaughan, "Brain–computer interfaces for communication and control," *Clinical Neurophysiology,* vol. 113, no. 6, pp. 767-791, 2002.

[8] H. Gürkök and A. Nijholt, "Brain–Computer Interfaces for Multimodal Interaction: A Survey and Principles," *International Journal of Human-Computer Interaction,* vol. 28, no. 5, pp. 292-307, 2012.